

BAB II


KAJIAN PUSTAKA

A. Kajian Teoritis

1. Paru-Paru

Paru-paru adalah organ vital yang berperan dalam proses pernapasan. Manusia memiliki sepasang paru-paru yang terletak di dalam rongga dada dan dilindungi oleh tulang rusuk. Organ ini berperan utama dalam proses pernapasan. Selain itu, paru-paru juga berfungsi sebagai organ ekskresi yang bertugas mengeluarkan sisa gas hasil pernapasan, seperti karbon dioksida (CO_2) dan uap air (H_2O) (Handayani, 2021).

Saat kita menghirup udara, paru-paru menyerap oksigen ke dalam aliran darah dan mengeluarkan karbon dioksida sebagai sisa metabolisme. Oleh karena itu, menjaga kesehatan paru-paru sangat penting untuk mencegah berbagai penyakit. Gangguan pada paru-paru dapat menyebabkan fungsinya menurun, seperti pada penyakit tuberkulosis. Untuk mendeteksi penyakit ini, diperlukan alat pencitraan medis yang mampu menampilkan gambaran organ dalam tubuh. Dengan alat tersebut, dokter dan ahli radiologi dapat mengidentifikasi penyakit dengan lebih cepat dan akurat (Rosyani et al., 2024).



Gambar 2.1 Struktur Paru-Paru

Sumber: Chaudhary (2024)


Pada Gambar 2.1 menunjukkan paru-paru terdiri dari dua bagian (kanan dan kiri) dengan lobus yang berbeda. Udara masuk melalui trakea, bercabang ke bronkus dan bronkiolus, lalu ke alveoli untuk pertukaran gas. Dilindungi pleura dan dibantu diafragma untuk bernapas .

2. Tuberkulosis

Tuberkulosis merupakan penyakit menular yang paling sering menyerang paru-paru dan disebabkan oleh bakteri *mycobacterium tuberculosis*. Tuberkulosis menyebar melalui udara ketika orang yang terinfeksi batuk, bersin, atau meludah (Lelewana et al., 2024). Pasien yang terinfeksi tuberkulosis akan memproduksi droplet yang mengandung sejumlah *basil* kuman tuberkulosis paru ketika mereka batuk, bersin, atau berbicara. Tuberkulosis adalah penyakit menular yang merupakan penyebab utama

kesehatan yang buruk, salah satu dari 10 penyebab utama kematian di seluruh dunia dan penyebab utama (Sudirman et al., 2022).

Kelainan tuberkulosis tergantung pada luasnya kerusakan, biasanya di lobus superior dan inferior. Pemeriksaan fisis dapat menunjukkan suara napas melemah, ronki basah, atau tanda penarikan paru. Pleuritis tuberkulosa ditandai dengan perkusi redup dan suara napas melemah, sedangkan limfadenitis tuberkulosa menyebabkan pembesaran kelenjar getah bening, terutama di leher atau ketiak (Isbaniah et al., 2021).



Gambar 2.2 *Apeks Lobus Superior dan Inferior*

Sumber: Isbaniah et al., (2021)

Pada tuberkulosis paru, infeksi lebih sering menyerang lobus superior, terutama di bagian apeks, karena aliran udara di area ini lebih sedikit, sehingga bakteri *mycobacterium tuberculosis* lebih mudah berkembang. Infeksi di lobus superior dapat menyebabkan peradangan, kerusakan jaringan paru, dan pembentukan kavitas atau rongga di dalam paru-paru. Sementara itu, lobus inferior juga bisa terpengaruh, terutama pada stadium lanjut, di mana infeksi

dapat menyebar ke bagian bawah paru-paru melalui saluran udara atau aliran darah. Kerusakan pada lobus inferior dapat memperburuk fungsi paru, menyebabkan gangguan pertukaran gas, sesak napas, serta penurunan kapasitas paru secara keseluruhan (Isbaniah et al., 2021).

3. Machine Learning

Machine Learning (ML) merupakan cabang dari kecerdasan buatan yang berfokus pada pengembangan algoritma dan model yang memungkinkan komputer belajar dari data tanpa perlu diprogram secara eksplisit untuk tugas tertentu. Dengan mengenali pola dalam data, ML memungkinkan sistem untuk meningkatkan kinerjanya seiring bertambahnya pengalaman. Arthur Samuel, salah satu pionir dalam bidang ini, mendefinisikan ML sebagai disiplin ilmu yang memberikan kemampuan kepada komputer untuk belajar secara mandiri tanpa instruksi pemrograman langsung (Bintoro et al., 2024).

Dalam pembelajaran mesin, terdapat dua jenis utama algoritma, yaitu pembelajaran terawasi (*supervised learning*) dan pembelajaran tanpa pengawasan (*unsupervised learning*). Dalam supervised learning, algoritma dilatih menggunakan data dengan pasangan input-output yang telah diketahui, sehingga model dapat belajar dari contoh untuk membuat prediksi. Contohnya meliputi pengenalan angka pada kode pos, klasifikasi tumor berdasarkan citra medis, dan deteksi penipuan kartu kredit. Meskipun membutuhkan proses pelabelan data yang cukup rumit, metode ini mudah dievaluasi dan memiliki performa yang terukur.

Sebaliknya, unsupervised learning tidak memiliki label output, sehingga algoritma mencari pola tersembunyi dalam data secara mandiri. Contoh penerapannya adalah pengelompokan pelanggan berdasarkan preferensi, identifikasi topik dalam teks, dan deteksi aktivitas abnormal pada situs web. Metode ini berguna untuk eksplorasi data tetapi lebih sulit dievaluasi dibandingkan supervised learning (Raharjo, 2021).

4. Deep Learning


Deep Learning (DL) merupakan cabang dari *Machine Learning* yang terinspirasi oleh cara kerja otak manusia melalui jaringan saraf tiruan atau *Artificial Neural Network* (ANN). Metode ini menggunakan jaringan dengan banyak lapisan neuron untuk mengekstraksi dan merepresentasikan fitur yang kompleks dari data secara hierarkis. Perbedaan utama antara Deep Learning dan pembelajaran mesin konvensional terletak pada jumlah serta tingkat kompleksitas lapisan neuron yang digunakan. Kemampuannya dalam mengenali pola dari data yang rumit dan abstrak membuatnya sangat efektif dalam berbagai bidang, seperti pengenalan citra, pemrosesan bahasa alami, dan pengenalan suara (Lubis et al., 2024).

Deep learning mampu melatih model kompleks untuk berbagai aplikasi, seperti pengenalan suara, pemrosesan bahasa alami, dan pengenalan gambar. Salah satu keunggulan utama dari deep learning adalah kemampuannya dalam mempelajari data yang tidak terstruktur atau tidak berlabel secara otomatis, sehingga lebih efektif dalam menyelesaikan tugas-

tugas yang sulit diatasi oleh metode pembelajaran mesin tradisional. Teknologi ini pun telah menjadi elemen penting dalam berbagai bidang, termasuk kecerdasan buatan, analisis *big data*, serta pengembangan teknologi canggih lainnya (Hafidzah et al., 2024).

5. Neural Network

Neural Network (NN), atau jaringan saraf tiruan, adalah model dalam kecerdasan buatan yang meniru cara kerja otak manusia. Terinspirasi dari neuron biologis (Herberg, 2023). NN terdiri dari lapisan input untuk menerima data, lapisan tersembunyi untuk memproses informasi, dan lapisan output untuk menghasilkan prediksi. Pembelajaran dalam jaringan ini dilakukan dengan menyesuaikan bobot antar neuron berdasarkan data, memungkinkan sistem mengenali pola dan meningkatkan akurasi. (Saptadi et al., 2025).



Gambar 2.3 *Single Perceptron*

Sumber: Mägdefrau et al., (2023)

Salah satu model paling sederhana dalam neural network adalah *perceptron*, yang pertama kali diperkenalkan oleh Frank Rosenblatt pada tahun 1958. *Perceptron* merupakan salah satu jenis Neural Network (NN) paling

sederhana yang terdiri atas satu lapisan input dan satu neuron output. Arsitektur dasar perceptron sering digunakan dalam permasalahan klasifikasi biner, di mana setiap data pelatihan direpresentasikan dalam bentuk pasangan $(\bar{X}, y)$. Dalam hal ini, $\bar{X}$ merupakan sekumpulan fitur berdimensi d , yang dapat dinyatakan sebagai:

$$\bar{X} = [x_1, x_2, \dots, x_d] \quad (2.1)$$

Sementara itu, y merupakan label kelas yang memiliki dua kemungkinan nilai, yaitu -1 atau $+1$. Tujuan utama dari perceptron adalah mempelajari pola dalam data $\bar{X}$ agar dapat memprediksi nilai y pada data baru yang belum pernah diobservasi sebelumnya. Pada perceptron, setiap fitur dalam lapisan input terhubung dengan bobot ($\bar{W}$) yang dinyatakan sebagai:

$$\bar{W} = [w_1, w_2, \dots, w_d] \quad (2.2)$$

Selain bobot, terdapat pula bias (b) yang berfungsi untuk menggeser batas keputusan dalam klasifikasi. Perhitungan utama dalam perceptron terjadi pada neuron output, di mana nilai y dihitung menggunakan kombinasi linier antara bobot dan fitur input sebagai berikut:

$$y = \bar{W} \cdot \bar{X} + b = \sum_{i=1}^d w_i x_i + b \quad (2.3)$$

Selanjutnya, nilai y akan diproses menggunakan fungsi aktivasi untuk menentukan prediksi akhir $\hat{y}$. Fungsi aktivasi ini memainkan peran penting


dalam menentukan apakah suatu neuron akan aktif atau tidak. Pada awalnya, perceptron menggunakan fungsi aktivasi Heaviside, yang dinyatakan sebagai:

$$y = \begin{cases} 1, & \text{jika } y \geq 0 \\ 0, & \text{jika } y < 0 \end{cases} \quad (2.4)$$

Fungsi ini berperan dalam mengklasifikasikan input ke dalam salah satu dari dua kelas yang tersedia. Seiring perkembangan penelitian dalam jaringan saraf tiruan, berbagai fungsi aktivasi lain telah diperkenalkan, seperti fungsi sigmoid, ReLU (Rectified Linear Unit), dan softmax (Herberg, 2023).

6. *Multi Layer Perceptron Neural Network (MLPNN)*

Multilayer Perceptron Neural Network (MLPNN) adalah jenis *Feedforward Neural Network (FNN)* yang terdiri dari lapisan input, satu atau lebih hidden layers, dan lapisan output. Setiap neuron di hidden layer menerima input dari lapisan sebelumnya, menerapkan transformasi non-linear melalui fungsi aktivasi, lalu mengirimkan hasilnya ke lapisan berikutnya (Herberg, 2023).



Gambar 2.4 *Feed-Forward Neural Network*

Sumber: Mägdefrau et al., (2023)


Pada struktur FFNN seperti pada Gambar 2.4, terdapat dua lapisan tersembunyi dengan masing-masing tiga neuron. Lapisan ini disebut tersembunyi karena proses perhitungannya tidak langsung terlihat pada output. Jumlah hidden layer menentukan kedalaman jaringan, sehingga FFNN dengan dua atau lebih hidden layer disebut *Deep Feedforward Neural Network* (DFNN) atau *Deep Neural Network* (DNN).

Keberadaan hidden layers memungkinkan FFNN menangani masalah yang lebih kompleks dibanding perceptron sederhana. Dengan membentuk pola dan batas keputusan yang lebih rumit, FFNN dapat mempelajari hubungan non-linear dalam data, menjadikannya efektif untuk klasifikasi dan regresi (Mägdefrau et al., 2023).

7. *Convolutional Neural Network*

Convolutional Neural Networks (CNN) adalah jenis arsitektur jaringan saraf tiruan yang terinspirasi oleh proses biologis, khususnya cara kerja korteks visual dalam otak manusia dalam mengenali pola dan objek dalam gambar. CNN dirancang untuk meniru konektivitas saraf pada otak, sehingga sangat efektif dalam pemrosesan data visual (Hosseini et al., 2020).

CNN pertama kali diperkenalkan oleh Yann LeCun pada tahun 1988 dan sejak itu telah menjadi komponen penting dalam banyak aplikasi teknologi, termasuk pengenalan gambar dan video, sistem rekomendasi, analisis gambar medis, dan bahkan pemrosesan bahasa alami. CNN merupakan salah satu pilar utama dari perkembangan dan kesuksesan teknologi Deep Learning.



Gambar 2.5 *Convolution Neural Network Architecture*

Sumber: Sidhart (2023)

Komponen-komponen utama yang ada di dalam CNN antara lain: input layer, convolution layer, pooling layer, flattening layer dan fully connected Layer (Setia Budi et al., 2024).

8. Input Layer

Pada lapisan ini, citra atau gambar digunakan sebagai input untuk jaringan saraf konvolusi. Citra merupakan representasi visual suatu objek dalam bentuk matriks atau array yang terdiri dari elemen-elemen kecil yang disebut piksel.

Sebagai lapisan pertama, lapisan masukan berfungsi menerima data sebelum diteruskan ke lapisan berikutnya. Dimensinya mengikuti format $\text{height} \times \text{width} \times \text{channel}$, yang menunjukkan ukuran tinggi, lebar, dan jumlah saluran warna pada citra, misalnya untuk format citra RGB: (224, 224, 3) dan format *greyscale*: (224,224,1).



Gambar 2.6 RGB to *Grayscale*

Sumber: Saptadi et al., (2025)


Pada Gambar 2.6 menampilkan citra asli berdimensi dua dengan tiga saluran warna, yaitu Merah (Red), Hijau (Green), dan Biru (Blue), yang memiliki rentang warna hingga 256. Citra tersebut memiliki ukuran tinggi (*height*) dan lebar (*width*), kemudian dikonversi ke format keabuan (*greyscale*), yang direpresentasikan dalam skala 0-255 dengan kedalaman 8 bit. Semakin tinggi intensitas warna, semakin besar nilai pikselnya, sedangkan semakin rendah intensitasnya, semakin kecil nilai piksel yang dihasilkan (Saptadi et al., 2025).

9. Convolution Layer

Menurut Hosseini et al., (2020), berbeda dengan pendekatan tradisional yang memproses seluruh input sekaligus, lapisan konvolusi bekerja dengan melakukan pemindaian (*scanning*) terhadap input menggunakan *receptive field* berukuran $k \times k$. Proses ini memungkinkan jaringan untuk fokus pada bagian kecil dari citra sebelum berpindah ke bagian lain. Sebagai contoh, input dalam dua dimensi dapat direpresentasikan sebagai matriks berikut:

$$\begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{p1} & x_{p2} & \dots & x_{pp} \end{bmatrix} \quad (2.5)$$

Setiap elemen x_{ij} dalam matriks ini mewakili skalar dari citra. Misalnya, jika citra berwarna (RGB), setiap nilai piksel menyimpan informasi intensitas warna dalam format 8-bit. Selama proses pemindaian, jaringan hanya memperhatikan area kecil (*patch*) berukuran $k \times k$, yang disebut receptive field, yang bergerak di seluruh citra dengan langkah tertentu yang disebut stride.



Gambar 2.7 Proses Konvolusi

Sumber: Saptadi et al., (2025)

Pemindaian dimulai dari sudut kiri atas dan bergerak ke kanan serta ke bawah dengan interval tertentu. Nilai stride (s) menentukan sejauh mana receptive field berpindah setiap langkahnya. Jika perlu, padding berupa nol dapat ditambahkan ke tepi citra agar ukuran keluaran tetap seragam.


Setiap receptive field dikaitkan dengan filter (*kernel*), yang berupa matriks dengan ukuran sama dengan receptive field. Secara keseluruhan, lapisan konvolusi berperan dalam mendeteksi berbagai fitur pada citra dengan cara mengaplikasikan beberapa filter pada seluruh bagian gambar. Proses ini

memungkinkan jaringan untuk mengenali pola visual tanpa harus memproses seluruh citra sekaligus, sehingga meningkatkan efisiensi dan akurasi model dalam tugas klasifikasi dan deteksi objek.

10. Pooling Layer

Pooling adalah teknik yang digunakan untuk mengurangi ukuran feature map sambil tetap mempertahankan informasi yang penting. Pooling layer membantu mengurangi jumlah parameter dan kompleksitas komputasi, sehingga mempercepat proses pelatihan model. Selain itu, pooling juga membuat model lebih andal terhadap pergeseran dan distorsi gambar, karena ekstraksi fitur menjadi lebih umum dan tidak bergantung pada lokasi piksel tertentu (Valizadeh & Wolff, 2022).

Umumnya, pooling dilakukan dengan stride q , mencakup seluruh feature map. Hasil pooling dari feature map berukuran $p \times p$ dengan jendela dan stride q adalah matriks $p/q \times p/q$, yang disebut pooled feature map. Seperti nilai maksimum (*max pooling*) atau rata-rata elemen (*avg pooling*) (Hosseini et al., 2020).




Gambar 2.8 Pooling Layer, Max Pooling and Avg Pooling

Sumber: Hosseini et al., (2020)

11. Flattening Layer

Flattening adalah proses mengubah feature map berdimensi 2D atau 3D menjadi vektor 1D, sehingga semua fitur dapat terhubung dengan neuron, membantu dalam reduksi dimensi (Gurov et al., 2022).



Gambar 2.9 Proses *Flattening Layer*

Sumber: Saptadi et al., (2025)

Gambar 2.9 adalah proses flattening dengan mengambil data dari dua kanal. Kanal 1, yang awalnya berdimensi 2×2 , dikonversi menjadi 4×1 , begitu pula dengan Kanal 2, yang mengalami perubahan serupa. Kedua kanal ini kemudian dikombinasikan dalam satu vektor berukuran 8×1 , yang merupakan gabungan dari seluruh data. Setelah proses ini, vektor yang dihasilkan akan digunakan dalam lapisan fully connected untuk klasifikasi (Saptadi et al., 2025).

12. Fully Connected Layer

Lapisan Fully Connected (FC) berfungsi untuk menggabungkan fitur-fitur yang telah dipelajari oleh lapisan sebelumnya guna menghasilkan prediksi


atau klasifikasi akhir. Setiap neuron dalam lapisan FC terhubung dengan semua aktivasi dari lapisan sebelumnya, membentuk jaringan yang padat untuk mempelajari hubungan kompleks antar fitur (Mienye et al., 2025).

Tahap akhir ini berfungsi untuk klasifikasi berdasarkan fitur yang telah diekstraksi oleh lapisan konvolusi. Selama pelatihan, dilakukan tuning hyperparameter untuk meningkatkan kemampuan classifier dalam membedakan kelas.

Parameter terbaik dari pelatihan digunakan sebagai acuan dalam mengklasifikasikan citra uji. Jika bobot fitur citra uji sesuai dengan ambang batas yang ditentukan, maka akan diklasifikasikan ke kelas yang paling mendekati. Semakin unik fitur antar kelas, semakin akurat klasifikasi.

13. Activation Functions

Activation function atau biasa disebut dengan fungsi aktivasi memiliki peran penting dalam jaringan saraf tiruan dengan mengubah input linear menjadi output non-linear. Non-linearitas ini memungkinkan jaringan mengenali pola kompleks yang tidak dapat ditangani oleh model linear. Dalam forward propagation, neuron memproses input, bobot, dan bias sebelum menerapkannya ke fungsi aktivasi untuk menghasilkan output. Fungsi ini juga berfungsi sebagai "gerbang" yang menentukan apakah sinyal akan diteruskan ke lapisan berikutnya, dengan jenis yang dipilih sesuai kebutuhan model (Saptadi et al., 2025).



Gambar 2.10 Fungsi Aktivasi

Sumber: Herberg, (2023)

Berikut adalah beberapa fungsi aktivasi yang umum digunakan dengan karakteristik dan kegunaannya sendiri (Saptadi et al., 2025), antara lain:

- Sigmoid mengubah input menjadi nilai antara 0 dan 1, cocok untuk klasifikasi biner. Namun, rentan terhadap vanishing gradient.
- Tanh memiliki output -1 hingga 1, membantu konvergensi lebih cepat namun tetap mengalami vanishing gradient.
- ReLU melewati nilai positif dan mengubah nilai negatif menjadi nol, lebih efisien tetapi bisa mengalami dying ReLU.

- d. Leaky ReLU adalah versi ReLU yang tetap memberi nilai kecil pada input negatif, mengatasi dying ReLU agar neuron tetap aktif.

14. Loss Functions

Loss Function atau fungsi kerugian merupakan rumus yang diminimalkan oleh algoritma pembelajaran mesin selama pelatihan model. Cara ini digunakan untuk mengetahui pengaturan parameter terbaik untuk model agar hasil yang dicapai optimal (Muttaqin et al., 2023). Dalam *neural network*, pemilihan *loss function* disesuaikan dengan tujuan yang ingin dicapai. Pada tugas klasifikasi, salah satu loss function yang umum digunakan adalah *Binary Cross-Entropy* (BCE).

BCE, atau log loss, digunakan dalam klasifikasi biner, di mana target label hanya terdiri dari dua kelas, yaitu 0 dan 1. BCE mengukur perbedaan antara probabilitas prediksi dan label sebenarnya, yang berasal dari konsep cross-entropy dalam teori informasi. Rumus BCE untuk satu data pelatihan adalah:

$$L(y, p) = -(y \log(p) + (1 - y) \log(1 - p)) \quad (2.6)$$

Loss ini diminimalkan ketika probabilitas prediksi p mendekati label sebenarnya y . BCE cocok untuk model berbasis *logistic regression* dan *neural network*, karena bersifat dapat didiferensiasi sehingga dapat digunakan dalam optimasi berbasis gradien.

Namun, BCE memiliki kelemahan saat menghadapi ketidakseimbangan kelas (*class imbalance*), di mana jumlah sampel dari satu kelas jauh lebih sedikit dibandingkan kelas lainnya. Untuk mengatasi ini, digunakan *Weighted Binary Cross-Entropy* (WBCE), yang memberikan bobot lebih tinggi pada kelas minoritas:

$$L_{weighted}(y, p) = -(w_1 \cdot y \log(p) + w_0 \cdot (1 - y) \log(1 - p)) \quad (2.7)$$


Dengan w_1 dan w_0 sebagai bobot untuk kelas positif dan negatif, yang biasanya diatur secara invers terhadap frekuensi kelas. Dengan demikian, BCE menjadi pilihan utama untuk tugas klasifikasi biner, sementara WBCE digunakan untuk menangani ketidakseimbangan kelas, memastikan bahwa model tetap belajar secara efektif meskipun distribusi data tidak merata (Terven et al., 2023).

15. DenseNet

DenseNet, diperkenalkan oleh peneliti dari Cornell University pada 2017, menghadirkan konsep dense connectivity, dimana setiap lapisan menerima input dari semua lapisan sebelumnya dan meneruskan outputnya ke semua lapisan berikutnya. Arsitektur ini meningkatkan aliran gradien, mengurangi fitur yang berulang, dan meningkatkan efisiensi parameter.

DenseNet telah terbukti sangat efektif dalam pemrosesan citra medis, seperti segmentasi gambar dan diagnosis penyakit. Misalnya, arsitektur ini digunakan untuk mengklasifikasikan retinopati diabetik dari citra fundus serta

menyegmentasi lesi paru-paru pada CT scan, menunjukkan fleksibilitas dan keunggulannya dalam berbagai aplikasi medis (Mienye et al., 2025).



Gambar 2.11 DenseNet Architecture

Sumber: (Mienye et al., 2025)

Setiap lapisan dalam model ini menerapkan batch normalization, aktivasi ReLU, dan konvolusi dengan filter 3×3 . Batch normalization digunakan untuk mempercepat pelatihan serta meningkatkan learning rate saat model dikembangkan. Pada setiap blok, input berupa matriks yang merepresentasikan piksel citra, kemudian diproses melalui batch normalization guna mengurangi risiko overfitting selama pelatihan (Agustina et al., 2024).

Layers	Output Size	DenseNet-121	DenseNet-169	DenseNet-201	DenseNet-264
Convolution	112×112	7×7 conv, stride 2			
Pooling	56×56	3×3 max pool, stride 2			
Dense Block (1)	56×56	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$
Transition Layer (1)	56×56	1×1 conv			
	28×28	2×2 average pool, stride 2			
Dense Block (2)	28×28	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$
Transition Layer (2)	28×28	1×1 conv			
	14×14	2×2 average pool, stride 2			
Dense Block (3)	14×14	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 64$
Transition Layer (3)	14×14	1×1 conv			
	7×7	2×2 average pool, stride 2			
Dense Block (4)	7×7	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 16$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$
Classification Layer	1×1	7×7 global average pool			
		1000D fully-connected, softmax			


Gambar 2.12 DenseNet Block

Sumber: Agustina et al., (2024)

Lapisan dalam dense block terdiri dari normalisasi batch, aktivasi ReLU, dan konvolusi menggunakan filter 3x3. Di antara dua blok yang berdekatan terdapat lapisan transisi yang bertugas mengubah ukuran fitur melalui konvolusi dan pooling. Tahap klasifikasi menggunakan global average pooling, diikuti oleh aktivasi softmax (Agustina et al., 2024).

16. Evaluation Metrics

Evaluation metrics adalah ukuran atau metode yang digunakan untuk menilai kinerja suatu model klasifikasi dalam menemukan solusi optimal selama proses pelatihan. Pemilihan metrik evaluasi yang tepat sangat penting untuk membedakan dan menentukan *classifier* yang optimal. Evaluasi performa model dilakukan menggunakan metrik evaluasi confusion matrix dan AUCROC yang digunakan untuk memvisualisasikan hasil prediksi (Fadli & Saputra, 2023).



Gambar 2.13 *Confusion Matrix*

Sumber: (Editorial Team Towards AI, 2021)

Confusion matrix, yang juga dikenal sebagai matriks kebingungan, merupakan tabel yang digunakan untuk mengevaluasi kinerja model klasifikasi dengan mengukur seberapa baik model tersebut melakukan klasifikasi pada data uji. Confusion matrix dapat menghasilkan fitur matrix yang terdiri dari nilai *accuracy*, *precision*, *recall*, dan *F1-Score* (Agustina et al., 2024).

a) Accuracy

Mengukur seberapa banyak prediksi yang benar dibandingkan dengan total data uji.

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (2.8)$$

b) Precision

Menunjukkan seberapa banyak prediksi positif yang benar dibandingkan dengan semua prediksi positif. Precision tinggi berarti model jarang memberikan prediksi positif yang salah.

$$Precision = \frac{TP}{(TP + FP)} \quad (2.9)$$

c) Recall

Mengukur seberapa banyak data positif yang benar-benar terdeteksi oleh model. Recall tinggi menunjukkan model tidak melewatkan banyak data positif.


$$Recall = \frac{TP}{(TP + FN)} \quad (2.10)$$

d) F1-Score

Rata-rata antara Precision dan Recall, digunakan ketika keseimbangan antara keduanya diperlukan. F1-Score tinggi berarti model memiliki keseimbangan yang baik antara Precision dan Recall.

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.11)$$

AUC/ROC curve merupakan metode untuk mengukur kinerja model dengan menampilkan hubungan antara true positive rate (sensitivity/recall) dan false positive rate (1 - specificity). Kurva ROC menggambarkan keseimbangan antara kekuatan prediksi dan tingkat kesalahan (Erickson & Kitamura, 2021).



Gambar 2.14 Metrics AUCROC

Sumber: (The MathWorks, 2025)

Pada Gambar 2.14 menunjukkan bahwa semakin dekat kurva ROC ke sudut kiri atas, semakin baik kinerja model secara keseluruhan. Sementara itu, AUCROC digunakan untuk meringkas kualitas model tanpa bergantung pada





ambang batas tertentu. Nilai AUCROC menunjukkan probabilitas bahwa skor dari sampel positif lebih tinggi dibandingkan dengan sampel negatif yang dipilih secara acak. Nilai AUCROC sebesar 1 menunjukkan model yang sempurna, sedangkan 0,5 setara dengan tebakan acak.

Namun, dalam kasus yang memerlukan sensitivitas atau spesifisitas tinggi, model dengan AUCROC lebih tinggi belum tentu yang paling optimal. Selain itu, karena AUCROC tidak dipengaruhi oleh prevalensi kelas, penggunaannya pada dataset yang tidak seimbang dapat memberikan gambaran yang terlalu optimis terhadap kinerja model (Erickson & Kitamura, 2021).

17. Flowchart

Flowchart merupakan representasi grafis yang menggambarkan langkah-langkah serta urutan prosedur dalam suatu program. Flowchart sistem menunjukkan alur proses dalam sistem, termasuk media input, output, serta jenis penyimpanan yang digunakan dalam pengolahan data. Sementara itu, flowchart program menggambarkan urutan proses secara detail menggunakan simbol-simbol tertentu, yang menunjukkan hubungan antara satu instruksi dengan instruksi lainnya dalam suatu program. Dalam pembuatan flowchart, seorang analis dan programmer perlu memperhatikan beberapa pedoman penting agar diagram yang dibuat dapat dipahami dengan jelas (Zalukhu et al., 2023). Berikut adalah simbol-simbol pada flowchart yang dapat dilihat pada Tabel 2.1.

Tabel 2.1 Simbol Flowchart

No	Simbol	Nama	Keterangan
1		Flow	Simbol yang digunakan untuk menggabungkan antara simbol yang satu dengan simbol yang lain
2		On-Page Reference	Simbol untuk keluar-masuk atau penyambungan proses dalam lembar kerja yang sama
3		Off-Page Reference	Simbol untuk keluar-masuk atau penyambungan proses dalam lembar kerja yang berbeda
4		Terminator	Simbol yang menyatakan awal atau akhir suatu program
5		Process	Simbol yang menyatakan suatu proses yang dilakukan komputer
6		Decision	Simbol yang menunjukkan kondisi tertentu yang akan menghasilkan dua kemungkinan jawaban yaitu ya dan tidak
7		Input/Output	Simbol yang menyatakan proses input atau output tanpa tergantung peralatan
8		Manual Operation	Simbol yang menyatakan suatu proses yang tidak dilakukan komputer
9		Document	Simbol yang menyatakan bahwa input berasal dari dokumen dalam bentuk fisik, atau output yang perlu dicetak

10		Predefine Process	Simbol untuk pelaksanaan suatu bagian (sub-program) atau prosedur
11		Display	Simbol yang menyatakan peralatan output yang digunakan
12		Preparation	Simbol yang menyatakan penyediaan tempat penyimpanan suatu pengolahan untuk memberikan nilai awal

Sumber: (Setiawan, 2021)





18. Unified Modeling Language (UML)



Unified Modeling Language (UML) adalah standar bahasa pemodelan perangkat lunak yang digunakan untuk merancang cetak biru (blueprint) dalam pengembangan sistem perangkat lunak (Pressman). UML dapat dimanfaatkan untuk visualisasi, spesifikasi, konstruksi, serta dokumentasi berbagai komponen dalam sistem. Secara analogi, seperti halnya seorang arsitek yang membuat cetak biru sebagai panduan bagi perusahaan konstruksi dalam membangun gedung, arsitek perangkat lunak menggunakan diagram UML untuk membantu programmer atau developer dalam merancang dan membangun perangkat lunak. Semakin dalam pemahaman terhadap berbagai istilah dalam UML, semakin efektif penggunaannya dalam proses pengembangan sistem (Sumiati et al., 2021). Berikut adalah diagram UML yang digunakan pada pengembangan sistem:

a) Use Case Diagram

Use case diagram merupakan representasi abstrak dari interaksi antara sistem dan aktor yang berperan di dalamnya. Oleh karena itu, pemilihan abstraksi yang sesuai sangat penting untuk menggambarkan pola interaksi antara admin dan pengguna dalam suatu sistem (Alvayet & Barrichelo, 2022). Selain itu, use case diagram juga berfungsi sebagai model hasil analisis dan perancangan sistem yang bertujuan untuk mendeskripsikan kebutuhan sistem, yang nantinya akan diterapkan oleh pengguna (Ocha Widya Susanti et al., 2022). Berikut adalah simbol-simbol use case yang dapat dilihat pada Tabel 2.2.

Tabel 2.2 Simbol Use Case

No	Simbol	Keterangan
1	 Actor	Mewakili peran orang, sistem yang lain, atau alat ketika berkomunikasi dengan sistem
2	 Use Case	Abstraksi dan interaksi antara sistem dan aktor
3	 Association	Abstraksi dari penghubung antara aktor dengan use case
4	 Generalisasi	Menunjukkan spesialisasi aktor untuk dapat berpartisipasi dengan use case

5		Menunjukkan bahwa suatu use case seluruhnya merupakan fungsionalitas dari use case lainnya
6		Menunjukkan bahwa suatu use case merupakan tambahan fungsional dari use case lainnya jika suatu kondisi terpenuhi



Sumber: Dicoding (2021)

b) Activity Diagram

Activity diagram adalah diagram yang menggambarkan seluruh aktivitas dalam sistem yang dirancang, termasuk peran setiap aktor di dalamnya (Alvayet & Barrichelo, 2022). Activity diagram merupakan model hasil analisis perancangan sistem yang menggambarkan alur proses atau aktivitas yang dilakukan oleh pengguna (Ocha Widya Susanti et al., 2022). Berikut adalah simbol-simbol pada activity diagram dapat dilihat pada Tabel 2.3.

Tabel 2.3 Simbol Activity Diagram

No	Simbol	Keterangan
1	 Initial Node	Sebuah diagram aktivitas memiliki sebuah status awal
2	 Activity	Aktivitas yang dilakukan sistem, aktivitas biasanya diawali dengan kata kerja

3	 Decision	Percabangan dimana ada pilihan aktivitas yang lebih dari satu
4	 Join Node	Penggabungan dimana lebih dari satu aktivitas yang digabungkan menjadi satu
5	 Final Node	Status akhir yang dilakukan sistem, sebuah diagram aktivitas memiliki sebuah status akhir
6	 Swimlane	Swimlane memisahkan organisasi bisnis yang bertanggung jawab terhadap aktivitas yang terjadi

Sumber: Dicoding (2021)




c) Sequence Diagram

Sequence diagram menggambarkan interaksi antara objek dalam sistem berdasarkan urutan waktu, menunjukkan tahapan kejadian yang dilakukan oleh aktor saat menjalankan sistem. Diagram ini berkaitan erat dengan use case dan memperlihatkan detail proses, termasuk pesan yang dikirim serta waktu terjadinya interaksi tersebut (Trilaksono, 2022).

Sequence diagram dibuat untuk memahami urutan kejadian dalam sistem guna mencapai output yang diharapkan. Selain itu, diagram ini memiliki tujuan yang hampir sama dengan activity diagram, yaitu menggambarkan alur kerja suatu aktivitas serta menunjukkan aliran data secara lebih rinci, termasuk data yang diterima atau dikirim dalam proses

tersebut (Sumirat et al., 2023). Berikut adalah simbol-simbol pada sequence diagram yang dapat dilihat pada Tabel 2.4.

Tabel 2.4 Simbol Sequence Diagram

No	Simbol	Keterangan
1	 Aktor	Entitas eksternal yang berinteraksi dengan sistem, digambarkan sebagai stick figure.
2	 Activation Box	Merepresentasikan durasi waktu suatu objek menjalankan tugasnya. Semakin lama proses berlangsung, semakin panjang activation box yang digambarkan dalam bentuk persegi panjang.
3	 Lifeline	Garis putus-putus yang menunjukkan keberlangsungan objek dalam sistem, dengan kotak berisi nama objek untuk menggambarkan aktivitasnya..
4	 Objek	Objek digambarkan dengan simbol sesuai jenisnya (Boundary, Entity, Aktor) dan berfungsi mencatat serta menggambarkan perilaku entitas dalam sistem.
5	 Message	Menunjukkan komunikasi antar objek dalam sistem dengan panah yang berurutan sepanjang lifeline. Lifeline dan messages adalah komponen utama sequence diagram.



Sumber: Sumirat et al., (2023)

d) Class Diagram

Class Diagram adalah representasi struktur yang menggambarkan hubungan antara class, package, dan objek, termasuk pewarisan, asosiasi, dan keterkaitan lainnya (Ramdany et al., 2024). Class Diagram berfungsi untuk menggambarkan struktur suatu sistem secara jelas, sehingga mempermudah pemahaman terhadap skema atau rancangan program.

Selain itu, diagram ini dapat digunakan dalam analisis bisnis untuk membangun model sistem dari perspektif bisnis. Dengan adanya Class Diagram, pengembang dan pemangku kepentingan dapat memperoleh gambaran menyeluruh mengenai sistem atau perangkat lunak, termasuk relasi yang terdapat di dalamnya (Sumirat et al., 2023). Berikut adalah simbol-simbol class diagram yang dapat dilihat pada Tabel 2.5

Tabel 2.5 Simbol Class Diagram

No	Simbol	Keterangan
1		Elemen utama dalam pemrograman berorientasi objek, yang digambarkan sebagai kotak dengan tiga bagian..
2		Hubungan antar kelas yang menunjukkan interaksi dengan panah terbuka untuk aliran pesan satu arah.
3		Hubungan keseluruhan dan bagian dalam suatu sistem, sering disebut sebagai relasi antar objek.

4 → Dependencies	Ketergantungan suatu kelas terhadap kelas lainnya, sering digunakan untuk menunjukkan bahwa suatu operasi dalam satu kelas membutuhkan kelas lain..
Sumber: Hafidzah et al., (2024)	

19. Agile Framework Scrum

Agile adalah metode pengelolaan proyek yang fleksibel dan iteratif, memungkinkan beradaptasi dengan perubahan serta meningkatkan kolaborasi. Agile membagi proyek menjadi bagian kecil yang dikerjakan dalam siklus berulang, memungkinkan hasil diberikan secara bertahap dengan umpan balik cepat. Metode ini banyak digunakan dalam pengembangan perangkat lunak, tetapi juga diterapkan di bidang lain, seperti pendidikan dan bisnis (Akour et al., 2024).



Gambar 2. 15 Agile Framework Scrum

Sumber: Akour et al., (2024)

Salah satu framework Agile yang populer adalah Scrum, yang berfokus pada pengembangan berbasis sprint (2–4 minggu) serta transparansi,

inspeksi, dan adaptasi. Dalam implementasi standar, Scrum melibatkan Product Owner, Scrum Master, dan Tim Pengembang. Namun, dalam penelitian ini, Scrum diadaptasi untuk pengembangan individu, sehingga seluruh peran tersebut dilakukan oleh satu orang pengembang. Artefak utama seperti Product Backlog dan Increment tetap digunakan untuk memastikan alur kerja terorganisir.

Proses pengembangan menggunakan Scrum mencakup perencanaan sprint, Daily Reflection (sebagai pengganti Daily Scrum dalam konteks individu), sprint review, dan sprint retrospective. Daily Reflection dilakukan dengan mencatat progres harian serta hambatan yang dihadapi selama pengembangan (Akour et al., 2024)

B. Kajian Empiris

Penelitian ini merujuk pada penelitian terdahulu yang membahas penerapan Convolutional Neural Network (CNN) dalam bidang medis, yang menunjukkan bahwa model ini dapat digunakan secara efektif untuk deteksi penyakit berdasarkan citra medis.

Penelitian yang dilakukan oleh Wicaksono & Hartato, (2025), menunjukkan bahwa InceptionV3 lebih unggul dibandingkan VGG16 dalam mendeteksi kanker otak menggunakan citra MRI. InceptionV3 mencapai akurasi 91.67% dengan loss 0.3329, sedangkan VGG16 hanya 82.14% dengan loss 0.5027. Evaluasi classification report menunjukkan bahwa InceptionV3 memiliki

precision, recall, dan F1-score lebih tinggi dibandingkan VGG16, terutama dalam mendeteksi kelas kanker.

Penelitian ini juga menerapkan fine-tuning dan augmentasi data untuk meningkatkan performa model. Hasilnya, InceptionV3 terbukti lebih andal dalam klasifikasi kanker otak dibandingkan VGG16. Namun, masih diperlukan pengembangan lebih lanjut, seperti peningkatan dataset dan eksplorasi teknik lain agar model lebih akurat dan stabil.

Penelitian yang dilakukan oleh Rachmawanto et al., (2024) menerapkan Convolutional Neural Network (CNN) dengan arsitektur ResNet-50 untuk mendeteksi tumor otak menggunakan citra MRI. ResNet-50 dipilih karena kemampuannya dalam menangani degradasi akurasi pada jaringan yang sangat dalam melalui konsep Residual Learning. Arsitektur ini menggunakan skip connections, yang memungkinkan gradien tetap stabil selama pelatihan dan mencegah vanishing gradient, sehingga model dapat belajar fitur yang lebih kompleks secara efisien.

Dalam penelitian ini, citra MRI mengalami pra-pemrosesan, termasuk resizing ke 227x227x3, normalisasi, dan pembagian dataset dengan rasio 80% untuk pelatihan dan 20% untuk pengujian. Model dilatih menggunakan optimizer Adam dengan fungsi cross-entropy loss untuk meningkatkan stabilitas konvergensi. Hasil evaluasi menunjukkan bahwa model memiliki akurasi sebesar 98.82%, dengan presisi 99.22%, recall 100%, dan F1-score 99.72%, yang mengindikasikan performa yang sangat tinggi dalam mengklasifikasikan jenis tumor otak, seperti

tumor jinak, meningioma, dan pituitary. Temuan ini menunjukkan bahwa ResNet-50 dapat menjadi metode yang efektif untuk diagnosis tumor otak berbasis citra MRI, memberikan potensi besar dalam peningkatan sistem deteksi dini dan pengelolaan penyakit ini.

Penelitian yang dilakukan oleh Mas'ud & Junta Zeniarja (2024) memanfaatkan arsitektur DenseNet dalam Convolutional Neural Network (CNN) untuk mendeteksi kanker payudara melalui citra mammografi. DenseNet dipilih karena kemampuannya untuk menghubungkan setiap lapisan dengan lapisan sebelumnya, memungkinkan informasi untuk diteruskan dan digunakan kembali secara lebih efisien. Hal ini mengurangi jumlah parameter yang diperlukan, meningkatkan transmisi informasi antar lapisan, dan membantu model menangkap fitur-fitur lebih detail dari citra medis.

Pada arsitektur DenseNet, setiap lapisan menerima input dari lapisan sebelumnya, menciptakan hubungan yang lebih kuat antar fitur dan memudahkan model untuk belajar pola yang lebih kompleks, yang penting dalam pengolahan citra medis. Model ini juga menggunakan bottleneck layers untuk mengurangi dimensi input sebelum diproses, dan transition layers untuk menjaga keseimbangan antara kompleksitas dan efisiensi komputasi.

Dalam penelitian ini, performa model cukup baik, ketidakseimbangan data antara gambar non-kanker dan kanker menjadi tantangan. Penelitian ini menunjukkan bahwa DenseNet dapat secara efektif digunakan untuk deteksi dini


kanker payudara, meningkatkan diagnosis medis dengan meminimalkan kesalahan prediksi dan mempercepat proses deteksi.

Penelitian yang dilakukan oleh Berliani et al., (2023) membandingkan model CNN transfer learning antara ResNet-50 dan VGG-16 untuk klasifikasi citra X-Ray paru-paru. Metode yang digunakan adalah transfer learning dengan dua arsitektur CNN pre-trained, di mana citra diubah ukurannya menjadi 299x299 piksel, lalu dilakukan augmentasi, rescaling, dan normalisasi untuk meningkatkan variasi data.

Model dilatih menggunakan Adam optimizer dengan learning rate 0,002, serta dropout 0,5 untuk mencegah overfitting. Dataset dibagi 90% untuk training dan 10% untuk testing, dengan epoch optimal ditemukan pada 200. Hasil eksperimen menunjukkan bahwa ResNet-50 memiliki akurasi lebih tinggi (95,13%) dibandingkan VGG-16 (91,45%) sementara VGG-16 lebih cepat dalam inferensi.

Berdasarkan penelitian terdahulu, penelitian ini menggunakan CNN dengan arsitektur DenseNet-121 untuk mendeteksi Tuberkulosis (TB) pada citra chest X-Ray. Model ini dipilih karena kemampuannya mengekstraksi fitur secara efisien dan memiliki akurasi tinggi dalam klasifikasi penyakit paru-paru. Dataset berlabel yang digunakan terdiri dari citra X-Ray pasien dengan dan tanpa TB, dilatih untuk menghasilkan model deteksi akurat. Hasilnya akan diimplementasikan dalam sistem web sebagai alat bantu diagnosis.

C. Kerangka Berpikir



Gambar 2.16 Kerangka Berpikir